

第四章 语法分析

语法分析

- 语法分析是编译过程的**核心部分**。
- 语法分析的基本任务是在词法分析识别出单词符号串的基础上，分析判断程序的**语法结构**是否符合语法规则。
- 语法分析器的任务是确定整个单词串是否构成**语法上**正确的程序。
- **语法分析的方法**通常分为两类：
自上而下分析法和自下而上分析法

4.1、文法的直观概念

- **文法**：一种描述语言语法结构的**形式规则**。它用**有限的**规则把语言的全部句子（可能为**无限**）描述出来。

无穷句子的有穷表示：我们使用句子表述语言。如果语言只含有有穷多个句子，则只需列出句子的有穷集就行了；但对于含有无穷句子的语言来讲，存在着如何给出它的**有穷表示**的问题。

文法

- 用文法可精确定义一个语言，并依据文法构造出识别该语言的自动机。因此，文法对程序语言和编译程序的构造具有重要意义，如程序语言的词法可用正规文法描述，语法可用上下文无关文法描述，而语义可用上下文有关文法描述。

以自然语言的句子为例：主语后跟随谓语和宾语，构成谓语的是动词，我们采用第3章曾介绍的**正则文法**来表示这种句子（如：**我是大学生**）的构成规则：

句子 → 主语 谓语 宾语

主语 → 代词 | 名词

代词 → 我 | 你 | 他

名词 → 王明 | 大学生 | 工人

谓语 → 动词



动词 → 是 | 学习

宾语 → 代词 | 名词

代词 → 我 | 你 | 他

名词 → 王明 | 大学生 | 工人


句子“我是大学生”与句子构成
规则的匹配过程（两种）



例如：“我是大学生”的构成符合上述规则，而“我大学生是”不符合上述规则，我们说它不是句子。

这些规则成为我们判别句子结构合法与否的依据，换句话说，这些规则被看成是一种元语言，用它来描述汉语句子的结构。

文法就是这样的一种描述元语言。



例：赋值表达式可描述为

〈赋值表达式〉 $\rightarrow$ 〈左部〉=〈右部〉

〈左部〉 $\rightarrow$ 〈标识符〉

〈右部〉 $\rightarrow$ 〈表达式〉

〈表达式〉 $\rightarrow$ 〈表达式〉〈算符〉〈表达式〉

〈表达式〉 $\rightarrow$ 〈标识符〉|〈常数〉

〈标识符〉 $\rightarrow$ a1|b123|salary|stu_age

〈常数〉 $\rightarrow$ 18|123|4.5|

〈算符〉 $\rightarrow$ + | - | * | /


这里“ $\Rightarrow$ ”读作“导出”或“派生出”。

而“ $::=$ ”（通常又简记为“ $\rightarrow$ ”）读作“定义为”或“由...组成”，而每一条规则又称作是产生式或重写式。这样的一种描述形式就称作是**BNF**（**Backus-Naur Form**）。

BNF:巴科斯范式，一种用形式化符号来描述给定语言的语法。

4.2、文法和语言

4.2.1、如何描述一种语言？

- 如果语言是有穷的（含有穷个句子），可以将句子逐一列出来表示：**外延法**。
 - 如果语言是无穷的（含无穷个句子），找出语言的**有穷表示**：**内涵法**。
- 

4.2、文法和语言

语言的有穷表示有两个途经：

- **文法**是按生成方式描述语言 — 用严格定义的文法规则来生成语言中的每个句子。
- **自动机**是按识别方式描述语言 — 用一个过程，当输入的一任意串**属于语言**（定义的合法句子集）时，该过程经有限次计算后就会停止并回答“是”；若不属于，要么能停止并回答“不是”，要么永远继续下去。

前面关于“我是大学生”及“赋值表达式”的例子中，涉及到如下的概念：

- 1. <...>所表示的是一个类概念，通常称作语法范畴或语法变量，如果用一个符号来代替，也称为非终结符(nonterminal)。所有规则中的非终结符构成了一个非空有穷集，记为 V_N 。
- 2. 上述两例中的“句子”及“赋值表达式”显然是最大的语法范畴，也是我们最感兴趣的非终结符，通常称作开始符号，记为 S 。
- 3. “大学生”、“我”、“是”、“a”、“+”等表示的是一个具体概念，用一个符号来表示，则称为终结符(terminal)。所有这样的符号同样构成了一个非空有穷集，记为 V_T 。
- 4. <代词>→我、<数字>→8等称作产生式(production)。所有产生式的集合显然是有穷的，记为 P 。

终结符号是指语言不可再分的基本符号，通常是一个语言的字母表；终结符代表了语法的最小元素，是一种个体记号。非终结符号也称语法变量，它代表语法实体或语法范畴；非终结符代表一个一定的语法概念，因此，一个非终结符是一个类、一个集合。例如，在程序语言中，可以把变量、常数、“+”、“*”等看作是终结符，而像“算术表达式”这个非终结符则代表着一定算术式组成的类，如 $i*(i+i)$ 、 $i+i+i$ 等；也即每个非终结符代表着由一些终结符和非终结符且满足一定规则的符号串组成的集合。

文法开始符号是一个特殊的非终结符，它代表文法所定义的语言中我们最终感兴趣的语法实体，即语言的目标，而其它语法实体只是构造语言目标的中间变量；如表达式文法的语言目标是表达式，而程序语言的目标通常为程序。

产生式(也称产生规则或规则)是定义语法实体的一种书写规则。一个语法实体的相关规则可能不止一个。例如，有：

$$P \rightarrow \alpha_1$$

$$P \rightarrow \alpha_2$$

$$P \rightarrow \alpha_n$$

为书写方便，可将这些有相同左部的产生式合并为一个，即缩写成

$$P \rightarrow \alpha_1 \mid \alpha_2 \mid \cdots \mid \alpha_n$$

其中，每个 $\alpha_i (i=1,2,\cdots,n)$ 称为 P 的一个候选式，直竖“ $\mid$ ”读为“或”，它与“ $\rightarrow$ ”一样是用来描述文法的元语言符号(即不属于 Σ 的字符)。

4.2.2、文法的定义：

$$G=(V_N, V_T, P, S)$$

- V_N 为非终结符号的集合
- V_T 为终结符号的集合
- S 为开始符，是一个非终结符，至少要在一条规则中作为左部出现。
- P 为规则（产生式）的集合
- V_N, V_T, P 是非空有穷集

$$V_N \cap V_T = \phi$$

$$V_N \cup V_T = V$$

词汇表 V (或字母表 Σ)

规则 (重写规则、产生式或生成式)：

是形如 $\alpha \rightarrow \beta$ 的 (α, β) 有序对，其中 α 为 Σ^+ 中的符号串，称为规则的左部， β 为 Σ^* 中的符号，称为规则的右部。 $\rightarrow$ 读为“定义为”

例：

文法 $G = (V_N, V_T, P, S)$ ，其中 $V_N = \{S\}$ ，
 $V_T = \{0, 1\}$ ， $P = \{S \rightarrow 0S1, S \rightarrow 01\}$

该文法只有一个非终结符号 S ，两个终结符号 0 和 1 ，两个产生式，开始符号是 S 。

一般不显式表示文法的四元组，只写产生式。约定：

- 1) 第一条产生式的左部是开始符号；
- 2) 用大写字母表示非终结符号，小写字母表示终结符号。或者用**尖括号**括起来的是**非终结符号**（能表示有意义的助记符），**不用尖括号**括起来的是**终结符号**。

例: $G = (V_N, V_T, P, S)$

$V_N = \{\text{标识符}, \text{字母}, \text{数字}\}$

$V_T = \{a, b, c, \dots, x, y, z, 0, 1, \dots, 9\}$

$P = \{ \langle \text{标识符} \rangle \rightarrow \langle \text{字母} \rangle$

$\langle \text{标识符} \rangle \rightarrow \langle \text{标识符} \rangle \langle \text{字母} \rangle$

$\langle \text{标识符} \rangle \rightarrow \langle \text{标识符} \rangle \langle \text{数字} \rangle$

$\langle \text{字母} \rangle \rightarrow a, \dots, z$

$\langle \text{数字} \rangle \rightarrow 0, \dots, 9 \}$

$S = \langle \text{标识符} \rangle$

练习：

1、 $G[S] :$ $S \rightarrow aAb$
 $A \rightarrow ab$
 $A \rightarrow aAb$
 $A \rightarrow \varepsilon$

2、 $G[S] :$ $S \rightarrow aAb$
 $A \rightarrow ab \quad A \rightarrow aAb \quad A \rightarrow \varepsilon$

3、 $G[S] :$ $S \rightarrow aAb$
 $A \rightarrow ab \mid aAb \mid \varepsilon$

3. 文法产生的语言

设文法 $G=(V_T, V_N, S, \xi)$ 且 $\alpha, \beta \in (V_T \cup V_N)^*$, 如果存在产生式 $A \rightarrow \delta$ ($\delta \in (V_T \cup V_N)^*$), 则称 $\alpha A \beta$ 可直接推出 $\alpha \delta \beta$, 即

$$\alpha A \beta \Rightarrow \alpha \delta \beta$$

其中“ $\Rightarrow$ ”表示直接推导出, 是应用产生规则进行推导的记号。注意“ $\Rightarrow$ ”与“ $\rightarrow$ ”不同, “ $\rightarrow$ ”是产生式中的定义记号。直接推导是对文法符号串 $\alpha A \beta$ 中的非终结符 A 用相应的产生式 $A \rightarrow \delta$ 的右部 δ 来替换, 从而得到 $\alpha \delta \beta$ 。

4.2.3、推导的定义： $(\Rightarrow, \overset{+}{\Rightarrow}, \overset{*}{\Rightarrow})$

1、 $\alpha \rightarrow \beta$ 是文法G的产生式，若有 v, w 满足：

$v = \gamma \alpha \delta, w = \gamma \beta \delta$ ，其中 $\gamma, \delta \in V^*$

则称 v 直接推导到 w ，记作 $v \Rightarrow w$

也称 w 直接归约到 v ，归约是推导的逆过程。

例：G $S \rightarrow 0S1, S \rightarrow 01$

$0S1 \Rightarrow 00S11$

$00S11 \Rightarrow 000S111$

$000S111 \Rightarrow 00001111$

$S \Rightarrow 0S1$

- 2、若存在 $v \Rightarrow w_1 \Rightarrow \dots \Rightarrow w_n (n > 0) = w$, 则记为 $v \overset{+}{\Rightarrow} w$, v 可一步或多步推导出 w , 或 w 可一步或多步归约到 v
- 3、若有 $v \overset{+}{\Rightarrow} w$, 或 $v = w$, 则记为 $v \overset{*}{\Rightarrow} w$, v 可0步或多步推导出 w , 或 w 可0步或多步归约到 v

例: $G: \quad S \rightarrow OS1, \quad S \rightarrow 01$

$OS1 \Rightarrow 00S11$

$00S11 \Rightarrow 000S111$

$000S111 \Rightarrow 00001111$

$S \Rightarrow OS1 \Rightarrow 00S11 \Rightarrow 000S111 \Rightarrow 00001111$

$S \overset{+}{\Rightarrow} 00001111$

$S \overset{*}{\Rightarrow} S \quad 00S11 \overset{*}{\Rightarrow} 00S11$

4.2.4、句型、句子的定义

有文法 G ，若开始符 $S \xRightarrow{*} x$ ，则称 x 是文法 G 的**句型**。

有文法 G ，若开始符 $S \xRightarrow{*} x$ ，且 $x \in V_T^*$ ，则称 x 是文法 G 的**句子**。

例： $G: S \rightarrow 0S1, S \rightarrow 01$

$S \Rightarrow 0S1 \Rightarrow 00S11 \Rightarrow 000S111 \Rightarrow 00001111$

G 的句型： $S, 0S1, 00S11, 000S111, 00001111$

G 的句子： $00001111, 01$

例： $G[E]:$ $E \rightarrow E+T | T$
 $T \rightarrow T * F | F$
 $F \rightarrow (E) | a$

$E \Rightarrow \underline{E} + T \Rightarrow \underline{T} + T \Rightarrow \underline{F} + T \Rightarrow a + \underline{T}$
 $\Rightarrow a + \underline{T} * F \Rightarrow a + \underline{F} * F \Rightarrow a + a * \underline{F} \Rightarrow a + a * a$

句子：用符号 a , $+$, $*$, $($ 和 $)$ 构成的算术表达式

4.2.5、语言的定义

由文法G生成的语言记为 $L(G)$,它是文法G的一切句子的集合:

$L(G)=\{x \mid S \xRightarrow{+} x, \text{ 其中 } S \text{ 为文法的开始符号, 且 } x \in V_T^*\}$

例: $G \quad S \rightarrow 0S1, S \rightarrow 01$ 的语言为:

$$L(G)=\{0^n 1^n \mid n \geq 1\}$$

例 文法 $G[S]$:

(1) $S \rightarrow aSBE$

(2) $S \rightarrow aBE$

(3) $EB \rightarrow BE$

(4) $aB \rightarrow ab$

(5) $bB \rightarrow bb$

(6) $bE \rightarrow be$

(7) $eE \rightarrow ee$

例 文法 $G[S]$:

(1) $S \rightarrow aSBE$

(2) $S \rightarrow aBE$

(3) $EB \rightarrow BE$

(4) $aB \rightarrow ab$

(5) $bB \rightarrow bb$

(6) $bE \rightarrow be$

(7) $eE \rightarrow ee$

$$L(G) = \{ a^n b^n e^n \mid n \geq 1 \}$$

文法和语言的关系:

- 1) G 生成的每个串都在 $L(G)$ 中
- 2) $L(G)$ 中的每个串确实能被 G 生成

文法的等价:

- 1) 若 $L(G1)=L(G2)$, 则称文法 $G1$ 和 $G2$ 是等价的。
- 2) 例: 文法 $G1$ $A \rightarrow 0R, A \rightarrow 01, R \rightarrow A1$
与 $G2$ $S \rightarrow 0S1, S \rightarrow 01$ 等价

例3.1试构造产生标识符的文法。

[解答]首先，标识符是以字母开头的字母数字串，我们用L表示“字母”类非终结符，用D表示“数字”类非终结符，而用T表示“字母或数字”类非终结符，则有：



例3.1试构造产生标识符的文法。

[解答]首先，标识符是以字母开头的字母数字串，我们用L表示“字母”类非终结符，用D表示“数字”类非终结符，而用T表示“字母或数字”类非终结符，则有：

$$L \rightarrow a \mid b \mid \cdots \mid z$$
$$D \rightarrow 0 \mid 1 \mid \cdots \mid 9$$
$$T \rightarrow L \mid D$$

其次，如果用S表示“字母数字串”类，则T是一字母或数字，ST也是字母数字串，即有

$$S \rightarrow T \mid ST$$

其中，产生式 $S \rightarrow T \mid ST$ 是一种左递归形式，由它可以产生一串T。

最后，作为“标识符”的非终结符I，它或者是一个字母，或者为一字母后跟字母数字串，即

$$I \rightarrow L \mid LS$$

因此，产生标识符的文法G[I]为：

$$G = (\{a, b, \dots, z, 0, \dots, 9\}, \{I, S, T, L, D\}, I, \xi)$$

$$\xi : I \rightarrow L \mid LS$$

$$S \rightarrow T \mid ST$$

$$T \rightarrow L \mid D$$

$$L \rightarrow a \mid b \mid \dots \mid z$$

$$D \rightarrow 0 \mid 1 \mid \dots \mid 9$$

练习：

(1) 设计文法G，使 $L(G)=\{ \omega \mid \omega \text{ 是不以0开始的奇数} \}$
不考虑负数。

(2) 设计文法S，使 $L(S)=\{ 0 \text{ 和 } 1 \text{ 个数相等的 } 0、1 \text{ 串} \}$

作业：

(1) 给出下面文法G[S]描述的语言

$$S \rightarrow SAS \mid y, \quad A \rightarrow xxA \mid x$$

(2) 设计下述语言的文法：不能被5整除的正偶数；

例3.2 写一文法，使其语言是奇数集合，但不允许出现以0打头的奇数。







图3 - 1奇数划分示意

例3.2写一文法，使其语言是奇数集合，但不允许出现以0打头的奇数。

[解答]根据题意，我们可以将奇数划分为如图3 - 1所示的三个部分，即最高位允许出现1~9，用非终结符B表示；中间部分可以出现任意多位数字0~9，每一位用非终结符D表示；最低位只允许出现1、3、5、7、9等奇数，用A表示。



由于中间部分可出现任意位，所以另引入了一个非终结符M，它包括最高位和中间位部分。假定开始符为N，则可得到文法G[N]为：

$$G=(\{0,1,\cdots,9\},\{N,A,M,B,D\},N,\xi)$$

$$\xi:N\rightarrow A \mid MA \quad /*一位数字 \mid 多位数字*/$$

$$M\rightarrow B \mid MD \quad /*仅两位数字(无中间位) \mid 多于两位数字*/$$

$$A\rightarrow 1 \mid 3 \mid 5 \mid 7 \mid 9$$

$$B\rightarrow 1 \mid 2 \mid 3 \mid 4 \mid 5 \mid 6 \mid 7 \mid 8 \mid 9$$

$$D\rightarrow 0 \mid B$$

考察本节知识点最典型的题目是：

1. 已知文法 $G[A]$ ，写出它定义的语言描述

如： $G[A]: A \rightarrow 0B \mid 1C$

$B \rightarrow 1 \mid 1A \mid 0BB$

$C \rightarrow 0 \mid 0A \mid 1CC$

2. 给出语言描述，构造文法.

如：构造一文法，其定义的语言是由算符 $+$ ， $*$ ， $(,)$ 和运算对象 a 构成的算术表达式的集合.

考察本节知识点最典型的题目是：

1. 已知文法 $G[A]$ ，写出它定义的语言描述

如： $G[A]: A \rightarrow 0B \mid 1C$

$B \rightarrow 1 \mid 1A \mid 0BB$

$C \rightarrow 0 \mid 0A \mid 1CC$

答案： $G[A]$ 定义的语言由0、1符号串组成，串中0和1的个数相同。

2. 给出语言描述，构造文法。

如：构造一文法，其定义的语言是由算符 $+$ ， $*$ ， $(,)$ 和运算对象 a 构成的算术表达式的集合。

考察本节知识点最典型的题目是：

1. 已知文法 $G[A]$ ，写出它定义的语言描述

如： $G[A]: A \rightarrow 0B \mid 1C$

$B \rightarrow 1 \mid 1A \mid 0BB$

$C \rightarrow 0 \mid 0A \mid 1CC$

答案： $G[A]$ 定义的语言由0、1符号串组成，串中0和1的个数相同。

2. 给出语言描述，构造文法。

如：构造一文法，其定义的语言是由算符 $+$ ， $*$ ， $(,)$ 和运算对象 a 构成的算术表达式的集合。

答案1： $G[E] \quad E \rightarrow E+T \mid T$

$T \rightarrow T * F \mid F$

$F \rightarrow (E) \mid a$

答案2： $G[E] \quad E \rightarrow E+E \mid E * E \mid (E) \mid a$

语法错误

程序结构不符合语法（包括词法）规则的错误。

例：一个具有三处语法错误的赋值语句

$A[x, y := 3, 1416 + T (T + H)$

$A[x, y$ ：中括号未闭合，缺少右中括号

3, 1416：小数点写成了逗号

$T (T + H)$ ：缺少一个算术运算符

语法错误可以在编译过程的**词法分析**阶段或**语法分析阶段**查找出来。对于语法错误，编译程序能比较准确地确定出错的位置（即在源程序中的位置）和错误的性质。